



UNIVERSIDAD
TECNOLÓGICA
METROPOLITANA
del Estado de Chile

INFORME TÉCNICO PARA EL TRABAJO DE ANÁLISIS

PARA EL RAMO DE COMPUTACIÓN PARALELA Y DISTRIBUIDA

Integrante(s):

Luna David Leon Chandia

Mei-ying Mamani León

José Miguel Vargas Moraga

Profesor:

Sebastián Salazar Molina

10 de Julio del 2026

ÍNDICE

INTRODUCCIÓN.....	3
DESARROLLO.....	4
DESCRIPCIÓN DE LA SOLUCIÓN IMPLEMENTADA.....	4
JUSTIFICACIÓN DE LAS LIBRERÍAS ESTADÍSTICAS UTILIZADAS.....	7
INTERPRETACIÓN NO TÉCNICA DE CADA RESULTADO.....	8
Imagen 1: Histogramas básicos del análisis exploratorio.....	9
Imagen 2: Frecuencia de ventas por canal.....	10
Imagen 3: Boxplot de monto aplicado por canal.....	11
Imagen 4: Histograma de monto aplicado.....	12
Imagen 5: Histograma de porcentaje de descuento.....	13
Imagen 6: Gráfico QQ de monto aplicado.....	14
Imagen 7: Matriz de correlación.....	15
Imagen 8: Boxplot de monto por segmento.....	16
Imagen 9: Contingencia entre segmento de monto y género.....	17
Imagen 10: Boxplot para análisis ANOVA.....	18
Imagen 11: Distribución de clientes por cluster.....	19
Imagen 12: Método del codo.....	20
Imagen 13: Clusters según monto y frecuencia de compra.....	21
Imagen 14: Clusters según recencia y monto.....	22
JUSTIFICACIÓN DE LAS TÉCNICAS UTILIZADAS.....	23
DIFICULTADES ENCONTRADAS Y CÓMO SE RESOLVIERON.....	25
ANÁLISIS DE TIEMPOS DE EJECUCIÓN DEL PIPELINE.....	26
CONCLUSIÓN.....	28
ANEXOS.....	30

INTRODUCCIÓN

En el contexto actual, las organizaciones generan y almacenan grandes volúmenes de datos provenientes de sus operaciones diarias. En el caso de Cruz Morada, cadena de farmacias utilizada como caso de estudio, la información de ventas se encuentra consolidada en un archivo CSV de gran tamaño que contiene datos asociados a transacciones, productos, canales de venta, locales y clientes. Este volumen de información representa una oportunidad para obtener conocimiento relevante, pero también plantea desafíos técnicos relacionados con la carga, limpieza, procesamiento y análisis eficiente de los datos.

El presente informe tiene como objetivo describir el desarrollo de una solución computacional orientada al procesamiento y análisis estadístico de datos de ventas, incorporando técnicas de procesamiento paralelo y herramientas de análisis exploratorio. Para ello, se implementó un pipeline en Python capaz de cargar el archivo mediante particiones, validar la calidad de los datos, tratar valores faltantes y atípicos, generar variables deducidas y aplicar pruebas estadísticas que permitan caracterizar el comportamiento de las ventas.

Además del análisis exploratorio, la solución incorpora una etapa de modelado descriptivo mediante clustering K-Means, cuyo propósito es segmentar clientes según patrones de comportamiento de compra. A diferencia de un modelo predictivo, este enfoque busca identificar grupos de clientes con características similares, considerando variables como frecuencia de compra, monto promedio, monto total, descuento promedio, edad y recencia. De esta forma, el análisis permite pasar desde una revisión general de las transacciones hacia una interpretación más orientada al negocio.

Desde el punto de vista computacional, el trabajo utiliza *Dask* para procesar el archivo CSV en particiones, lo que permite trabajar con una gran densidad de registros sin la necesidad de cargar todo el dataset directamente en memoria. También se incorporan mecanismos de paralelismo en las etapas del análisis, como por ejemplo, en la ejecución de pruebas estadísticas independientes. No obstante, el flujo general del programa se mantiene organizado de manera secuencial por etapas, ya que cada fase depende de los resultados generados previamente.

En resumen, este informe presenta el diseño, implementación e interpretación de una solución que combina procesamiento eficiente de datos, análisis estadístico y modelado descriptivo. Los resultados obtenidos permiten caracterizar las ventas de Cruz Morada, identificar relaciones entre variables, reconocer diferencias entre grupos y generar perfiles de clientes que pueden apoyar futuras decisiones comerciales.

DESARROLLO

DESCRIPCIÓN DE LA SOLUCIÓN IMPLEMENTADA

La solución implementada corresponde a un *pipeline* de procesamiento, análisis estadístico y modelado descriptivo desarrollado en Python, orientado al análisis de un archivo CSV de gran tamaño con información de ventas de la empresa Cruz Morada. El objetivo principal es construir una herramienta capaz de cargar, validar, limpiar, transformar, analizar y modelar los datos de manera eficiente, utilizando técnicas de procesamiento paralelo y metodologías estadísticas que permitan obtener conocimiento útil para la toma de decisiones.

El programa se ejecuta desde la línea de comandos mediante la instrucción `python3 main.py data/ventas_completas.csv`. Al iniciar, el sistema valida la existencia del archivo de entrada y configura una variable de entorno `CPYD_SEED` la cual se utiliza para todas las acciones que requieran azar. En caso de que esta variable no esté definida, se utiliza el valor por defecto 42. Esta configuración permite asegurar reproducibilidad de los resultados que utilicen generadores de números *random*, en esto se incluyen muestreo, selección de registros o algoritmos con componentes aleatorios, como el *clustering K-Means*.

La primera etapa corresponde a la carga del archivo CSV utilizando *Dask DataFrame*, herramienta que permite trabajar con grandes volúmenes de datos mediante particiones. En esta versión, el archivo fue cargado con 3.242.878 registros, 15 columnas y 10 particiones. Esta decisión permite evitar la carga completa del archivo en memoria RAM, optimizando el uso de recursos y manteniendo la ejecución viable para archivos de gran tamaño.

Posteriormente, se realiza una etapa de validación del *dataset*. En esta fase se convierten las columnas numéricas al tipo correspondiente, tales como SKU, UNIDADES, PORCENTAJE DESCUENTO, MONTO APLICADO, BOLETA, LOCAL y GENERO. Además, se aplican reglas de dominio para asegurar la consistencia de los datos. Por ejemplo, el porcentaje de descuento debe encontrarse entre 0 y 1, el género debe tomar valores válidos y las fechas deben poder convertirse correctamente a formato temporal.

Luego se ejecuta un diagnóstico inicial del *dataset*, donde se generan archivos con información sobre tipos de columnas, valores nulos, duplicados y estadísticas descriptivas simples. Estos resultados se almacenan en la carpeta `output/diagnostico/`, permitiendo documentar el estado inicial de los datos antes del preprocesamiento.

En la etapa de preprocesamiento se identifican valores faltantes y valores extremos. Para detectar *outliers* se utiliza el método del rango intercuartílico, conocido como *IQR*, debido a que es una técnica robusta frente a distribuciones no normales. Los valores detectados como atípicos son tratados como valores problemáticos y posteriormente se aplica una estrategia de limpieza según el porcentaje de datos afectados.

La estrategia de tratamiento de valores nulos y problemáticos se basa en umbrales. Si una variable presenta un porcentaje bajo de nulos, se eliminan los registros afectados; si presenta un porcentaje intermedio, se imputan los datos mediante la mediana; y si supera un umbral alto, la variable puede ser descartada por perder confiabilidad. Esta estrategia permite conservar la mayor cantidad de información útil sin comprometer la calidad del análisis.

Después de limpiar las variables originales, el sistema crea variables deducidas que enriquecen el análisis. Entre ellas se incluyen MONTO_POR_UNIDAD, EDAD, HORA_TRANSACCION, FRECUENCIA_COMPRA, RECENCIA, ES_FIN_DE_SEMANA, SEGMENTO_MONTO y MONTO_BRUTO. Estas variables permiten analizar el comportamiento de compra desde distintas perspectivas, tales como el valor promedio pagado por unidad, edad aproximada del cliente, antigüedad de la compra, frecuencia de compra y clasificación del monto de venta.

Las variables deducidas también son validadas y limpiadas. Por ejemplo, se controlan edades fuera de rangos lógicos, montos negativos o valores inconsistentes. Posteriormente, algunas variables numéricas son normalizadas mediante estandarización, restando la media y dividiendo por la desviación estándar. Los parámetros utilizados en este proceso se guardan en formato *JSON*, lo que permite mantener trazabilidad y reproducibilidad.

Luego del preprocesamiento, se ejecuta el análisis exploratorio estadístico. Esta etapa genera estadísticas descriptivas, tablas de frecuencia, histogramas, curvas de densidad, *QQ plots*, *boxplots*, matrices de correlación, pruebas de normalidad, pruebas de asociación categórica, *ANOVA* y pruebas *post-hoc* de *Tukey*. Los resultados se organizan en carpetas dentro de *output/analysis/* y *output/graficos/*, facilitando su revisión e incorporación al informe.

Finalmente, en esta última versión se agregó una etapa de modelado descriptivo mediante *clustering K-Means*. Esta etapa se ejecuta después del análisis exploratorio y tiene como objetivo segmentar clientes según su comportamiento de compra. A diferencia de un modelo predictivo, el propósito no es anticipar una venta futura, sino identificar perfiles de clientes con características similares.

Para construir el modelo de *clustering*, el *dataset* se agrupa a nivel de CODIGO CLIENTE. A partir de esta agrupación se generan variables resumen como COMPRA_CUENTA, MONTO_APLICADO_PROMEDIO, MONTO_APLICADO_TOTAL, DESCUENTO_PROMEDIO, EDAD_PROMEDIO, RECENCIA_DIAS y MONTO_POR_UNIDAD_PROMEDIO. Luego, se seleccionan clientes válidos, se eliminan valores nulos o infinitos y se aplica una muestra controlada para evitar problemas de memoria. En esta ejecución, el universo de clientes disponibles fue de 1.177.083, pero se utilizó una muestra de 30.000 clientes para el *clustering*.

Antes de aplicar *K-Means*, las variables fueron estandarizadas mediante *StandardScaler*, ya que este algoritmo es sensible a la escala de los datos. Posteriormente, se aplicó el método del codo evaluando valores de *k* entre 2 y 8, y se seleccionó *k* = 3 como número de clusters. El modelo final se ejecutó con *random_state* igual a la semilla definida y *n_init* = 10, asegurando estabilidad y reproducibilidad.

Los resultados del modelado se guardaron en output/modelado/clustering/, incluyendo los archivos clientes_con_cluster.csv, resumen_clusters.csv, metricas_clustering.csv, metodo_codo.csv e interpretacion_clusters.txt. Además, se generaron gráficos en output/graficos/modelado/, tales como distribución de clientes por *cluster*, método del codo, relación entre monto y frecuencia, y relación entre recencia y monto.

JUSTIFICACIÓN DE LAS LIBRERÍAS ESTADÍSTICAS UTILIZADAS

Para el desarrollo de la solución se utilizaron distintas librerías de Python, seleccionadas según su utilidad en el procesamiento de grandes volúmenes de datos, análisis estadístico, visualización y modelado descriptivo.

La librería principal para la carga y procesamiento de datos fue *Dask*, ya que permite trabajar con archivos grandes mediante particiones y ejecución paralela. Esta herramienta fue fundamental porque el archivo de entrada contiene más de tres millones de registros, por lo que cargarlo completamente con *Pandas* podría generar un consumo excesivo de memoria.

También se utilizó *Pandas*, principalmente para trabajar con resultados ya calculados, tablas resumen, estadísticas descriptivas y archivos CSV de salida. *Pandas* es útil en las etapas donde el volumen de datos ya fue reducido, por ejemplo, al generar tablas de diagnóstico, resultados de pruebas estadísticas o resúmenes del modelo de *clustering*.

La librería *NumPy* fue utilizada para operaciones numéricas, manejo de valores nulos, reemplazo de infinitos y cálculos matemáticos generales. Su uso permite realizar operaciones eficientes y consistentes durante la limpieza, transformación y preparación de datos.

Para el análisis estadístico se utilizó *SciPy*, especialmente en pruebas de normalidad, correlaciones, pruebas Chi-cuadrado y ANOVA. Esta librería permite aplicar pruebas estadísticas ampliamente aceptadas, lo que aporta rigor metodológico al análisis.

La librería *Statsmodels* fue utilizada como complemento para análisis estadísticos más avanzados, especialmente para pruebas *post-hoc* como *Tukey*. Esta prueba permite profundizar los resultados del ANOVA, identificando entre qué grupos existen diferencias significativas.

Para la visualización de resultados se utilizó *Matplotlib*, ya que permite generar gráficos como histogramas, curvas de densidad, QQ plots, boxplots, heatmaps, gráficos de barras y gráficos de dispersión. Estas visualizaciones ayudan a interpretar patrones, distribuciones, diferencias entre grupos y resultados del *clustering* de forma más clara.

En esta última versión también se incorporó *Scikit-learn*, debido a que se agregó una etapa de modelado descriptivo. Esta librería fue utilizada para aplicar *StandardScaler*, *KMeans* y *silhouette_score*. *StandardScaler* permite normalizar las variables antes del *clustering*, *KMeans* permite segmentar clientes según similitud de comportamiento y *silhouette_score* permite evaluar la calidad de la separación entre los clusters.

Finalmente, se utilizaron librerías estándar como *os*, *pathlib*, *json* y *time* para manejo de rutas, creación de carpetas, almacenamiento de parámetros, lectura de variables de entorno y medición de tiempos de ejecución. Estas herramientas permiten mantener el pipeline organizado, reproducible y trazable.

INTERPRETACIÓN NO TÉCNICA DE CADA RESULTADO

Como parte del análisis exploratorio y del modelado descriptivo, el código genera una gran cantidad de gráficos asociados a distribuciones, frecuencias, correlaciones, pruebas estadísticas, análisis de varianza y segmentación de clientes. Sin embargo, para este apartado se seleccionaron únicamente las visualizaciones más relevantes, con el objetivo de facilitar la interpretación de los resultados y evitar sobrecargar el informe con gráficos repetitivos o de menor aporte explicativo. Por esta razón, las figuras incluidas a continuación representan los resultados más significativos para comprender el comportamiento de las ventas, la relación entre variables y los perfiles de clientes obtenidos mediante el modelo de *clustering K-Means*.

Como se observa en la Figura 1, el análisis exploratorio inicial permite visualizar el comportamiento general de las variables principales del conjunto de datos. A través de los histogramas básicos se aprecia que las ventas no se distribuyen de manera uniforme, ya que existen variables con alta concentración en ciertos rangos y otras con poca variabilidad. En particular, la variable UNIDADES presenta un comportamiento prácticamente constante, lo que indica que la mayoría de las transacciones corresponden a compras unitarias. En términos simples, esto significa que las diferencias entre ventas no se explican principalmente por la cantidad de productos comprados, sino por factores como el precio del producto, el descuento aplicado, el local, el canal de venta o el perfil del cliente.




Imagen 1: Histogramas básicos del análisis exploratorio.

La Figura 2 muestra la frecuencia de ventas por canal. En ella se observa que las ventas se concentran principalmente en el canal POS, mientras que los demás canales presentan una

participación mucho menor. Este resultado evidencia un desbalance importante en la variable CANAL. Desde una mirada de negocio, esto indica que la operación de Cruz Morada sigue dependiendo mayoritariamente de ventas presenciales o de punto de venta. Además, esta concentración debe considerarse al interpretar pruebas estadísticas por canal, ya que las comparaciones pueden verse limitadas cuando una categoría tiene muchos más registros que otra.




Imagen 2: Frecuencia de ventas por canal

En la Figura 3 se presenta el boxplot de MONTO APLICADO por CANAL. Esta visualización permite comparar la distribución de los montos de venta entre los distintos canales. Se observan diferencias en la distribución de los montos, aunque la interpretación debe realizarse con cautela debido al desbalance de registros entre canales. En términos simples, el gráfico ayuda a identificar si un canal tiende a generar ventas de mayor o menor monto, pero para confirmar diferencias significativas es necesario complementar la observación visual con pruebas estadísticas.




Imagen 3: Boxplot de monto aplicado por canal.

La Figura 4 muestra la distribución de la variable MONTO APLICADO. En este histograma se observa que los montos pagados por los clientes se concentran principalmente en rangos bajos y medios, mientras que existen menos registros con valores más altos. Desde una perspectiva comercial, este resultado permite entender cuál es el rango de ticket más frecuente y sirve como base para analizar el comportamiento de compra de los clientes.




Imagen 4: Histograma de monto aplicado.

Como se observa en la Figura 5, el histograma de PORCENTAJE DESCUENTO evidencia que los descuentos son una variable relevante dentro de las ventas analizadas. La media aproximada de esta variable fue cercana a 0,39, lo que indica que los descuentos aplicados tienden a ser frecuentes y relativamente altos. En términos simples, esto sugiere que la estrategia comercial de Cruz Morada está fuertemente asociada al uso de descuentos, por lo que esta variable debe considerarse al interpretar el monto final pagado por los clientes.




Imagen 5: Histograma de porcentaje de descuento.

La Figura 6 corresponde al gráfico QQ de MONTO APLICADO, el cual permite evaluar visualmente si esta variable se comporta como una distribución normal. En este caso, los puntos no siguen completamente la línea teórica, lo que respalda la idea de que los montos de venta no se distribuyen de forma normal. Esto coincide con las pruebas de normalidad, donde se obtuvieron p-values menores a 0,05. En términos simples, los datos no presentan una forma simétrica tradicional, por lo que fue correcto utilizar métodos más robustos para algunas comparaciones, como la correlación de Spearman.




Imagen 6: Gráfico QQ de monto aplicado.

En la Figura 7 se presenta la matriz de correlación entre variables numéricas. Esta visualización permite identificar relaciones entre variables del conjunto de datos. En el análisis se observa una relación positiva entre PORCENTAJE DESCUENTO y MONTO APLICADO, con una correlación aproximada de 0,55 y p-value igual a 0,000. Esto significa que, en general, las ventas con mayor porcentaje de descuento tienden a estar asociadas a montos aplicados más altos. También se observa una relación muy alta entre MONTO APLICADO y MONTO_BRUTO, lo cual es esperable porque el monto bruto se calcula a partir del monto aplicado y del descuento. Por esta razón, ambas variables deben interpretarse con cuidado para no duplicar información dentro del análisis.




Imagen 7: Matriz de correlación

La Figura 8 muestra el boxplot de monto por segmento. Esta visualización permite comparar los grupos definidos según el nivel de venta. A partir del gráfico se puede observar que los segmentos bajo, medio y alto presentan comportamientos distintos en cuanto al monto aplicado. En términos de negocio, esta clasificación ayuda a comprender cómo se distribuyen las transacciones según su valor y permite analizar si ciertos grupos de clientes o tipos de compra se concentran en segmentos específicos. Además, esta variable fue útil para realizar pruebas de asociación con variables categóricas como GENERO.




Imagen 8: Boxplot de monto por segmento

En la Figura 9 se observa la relación entre SEGMENTO_MONTO y GENERO mediante una tabla o gráfico de contingencia. La prueba Chi-cuadrado aplicada entre ambas variables obtuvo un p-value menor a 0,05, por lo que se puede afirmar que existe una relación estadísticamente significativa. Sin embargo, el valor de Cramér's V fue cercano a 0,098, lo que indica que la asociación es débil. En términos simples, aunque existe una diferencia estadística entre género y segmento de monto, esta diferencia no necesariamente representa un impacto fuerte desde el punto de vista del negocio.

Frecuencias observadas: SEGMENTO_MONTO vs GENERO




Imagen 9: Contingencia entre segmento de monto y género

La Figura 10 corresponde al boxplot utilizado para el análisis ANOVA. Esta visualización permite comparar los montos de venta entre distintos grupos, especialmente por LOCAL. El resultado del ANOVA aplicado sobre MONTO APLICADO por LOCAL obtuvo un p-value menor a 0,05, lo que indica que existen diferencias significativas entre los montos de venta de distintos locales. Desde una perspectiva comercial, esto sugiere que no todos los puntos de venta presentan el mismo comportamiento, por lo que algunos locales podrían concentrar tickets más altos o patrones de compra distintos. Esta información puede ser útil para evaluar desempeño por sucursal o diseñar estrategias diferenciadas.




Imagen 10: Boxplot para análisis ANOVA

La Figura 11 muestra la distribución de clientes por cluster luego de aplicar el modelo descriptivo K-Means. El modelo permitió segmentar a los clientes en tres grupos principales. El Cluster 0 representa aproximadamente el 12,79% de los clientes analizados, el Cluster 1 representa aproximadamente el 41,45% y el Cluster 2 representa aproximadamente el 45,76%. Esta distribución muestra que la mayor parte de los clientes se concentra en los clusters 1 y 2, mientras que el Cluster 0 corresponde a un grupo más pequeño, pero con características de mayor valor comercial.




Imagen 11: Distribución de clientes por cluster

En la Figura 12 se presenta el método del codo, utilizado para evaluar distintos valores de k antes de aplicar K-Means. Este método permite observar cómo disminuye la inercia a medida que aumenta la cantidad de clusters. En términos simples, ayuda a identificar un número razonable de grupos sin elegirlo de forma completamente arbitraria. Para mantener una solución simple, explicable y coherente con el informe, se seleccionó $k = 3$, lo que permitió obtener tres perfiles generales de clientes.




Imagen 12: Método del codo

La Figura 13 muestra la relación entre monto y frecuencia de compra por cluster. A partir de esta visualización se observan diferencias relevantes entre los grupos de clientes. El Cluster 0 presenta la mayor frecuencia promedio de compra, cercana a 8,4 compras por cliente, y el mayor monto total promedio, cercano a \$76.616. Por esta razón, puede interpretarse como un grupo de clientes frecuentes, recientes y de mayor valor. El Cluster 1 presenta una frecuencia menor, cercana a 2,35 compras, pero con un monto aplicado promedio alto, cercano a \$9.787, por lo que corresponde a clientes que compran menos veces, pero con tickets relativamente altos. El Cluster 2 presenta la menor frecuencia promedio, cercana a 1,54 compras, y el menor monto aplicado promedio, cercano a \$4.376, por lo que representa clientes de menor actividad y menor valor de compra.




Imagen 13: Clusters según monto y frecuencia de compra

Finalmente, la Figura 14 presenta la relación entre recencia y monto por cluster. Esta visualización permite complementar la interpretación anterior, incorporando la antigüedad de la última compra. El Cluster 0 presenta una recencia baja, cercana a 20 días, lo que indica que corresponde a clientes más recientes o activos. El Cluster 1 tiene una recencia promedio cercana a 56 días, por lo que representa clientes con actividad intermedia. En cambio, el Cluster 2 presenta la mayor recencia, aproximadamente 106 días, lo que permite interpretarlo como un grupo de clientes menos activos o más alejados en el tiempo. Desde una perspectiva comercial, esta segmentación puede apoyar estrategias diferenciadas, como fidelización para clientes frecuentes, campañas para clientes de ticket alto y acciones de reactivación para clientes menos activos.




Imagen 14: Clusters según recencia y monto

El gráfico de clusters según recencia y monto permite complementar la interpretación anterior, incorporando la antigüedad de la última compra. El Cluster 0 presenta una recencia baja, cercana a 20 días, lo que indica que corresponde a clientes más recientes o activos. El Cluster 1 tiene una recencia promedio cercana a 56 días, por lo que representa clientes con actividad intermedia. En cambio, el Cluster 2 presenta la mayor recencia, aproximadamente 106 días, lo que permite interpretarlo como un grupo de clientes menos activos o más alejados en el tiempo. Desde una perspectiva comercial, esta segmentación puede apoyar estrategias diferenciadas, como fidelización para clientes frecuentes, campañas para clientes de ticket alto y acciones de reactivación para clientes menos activos.

En general, los resultados permiten concluir que el conjunto de datos contiene información útil para caracterizar ventas, analizar diferencias entre locales, observar el efecto de los descuentos y segmentar clientes según comportamiento de compra. Los gráficos respaldan visualmente los resultados estadísticos y facilitan una interpretación más clara para usuarios no técnicos. Además, el modelo de clustering permite pasar desde un análisis descriptivo general hacia una clasificación práctica de clientes, identificando perfiles que pueden servir de apoyo para decisiones comerciales, campañas de fidelización y estrategias de reactivación.

JUSTIFICACIÓN DE LAS TÉCNICAS UTILIZADAS

La carga particionada mediante *Dask* fue utilizada porque el archivo de entrada contiene más de tres millones de registros. Esta técnica permite dividir el procesamiento en varias particiones, optimizando el uso de memoria y facilitando el trabajo con grandes volúmenes de datos. Esto responde directamente al objetivo del trabajo de procesar archivos grandes de forma eficiente.

La validación de tipos y reglas de dominio fue necesaria para asegurar la calidad de los datos antes de analizarlos. Por ejemplo, un porcentaje de descuento fuera del rango 0 a 1 o una fecha inválida podrían distorsionar los resultados. Por esta razón, los valores inconsistentes fueron tratados como nulos para su posterior limpieza.

La detección de *outliers* mediante *IQR* se utilizó porque es una técnica robusta y adecuada cuando los datos no siguen una distribución normal. En ventas, los valores extremos pueden representar tanto errores como casos reales de negocio, por lo que esta técnica permite identificarlos de forma controlada sin depender de la media y desviación estándar.

La limpieza estratificada de valores nulos fue utilizada porque no todas las columnas deben tratarse de la misma manera. Si el porcentaje de nulos es bajo, eliminar registros tiene poco impacto. Si el porcentaje es moderado, imputar con mediana permite conservar información. Si el porcentaje es demasiado alto, la variable pierde confiabilidad y puede ser descartada.

La creación de variables deducidas se justifica porque las columnas originales no siempre permiten observar directamente patrones relevantes. Variables como *EDAD*, *RECENCIA*, *MONTO_POR_UNIDAD*, *MONTO_BRUTO* y *SEGMENTO_MONTO* permiten obtener información más útil sobre el comportamiento de compra y facilitan tanto el análisis estadístico como el modelado posterior.

La normalización se aplicó porque algunas técnicas estadísticas y de modelado pueden verse afectadas por la escala de las variables. En particular, *K-Means* requiere que las variables estén estandarizadas, ya que calcula distancias entre observaciones. Si una variable tiene valores mucho más grandes que otra, podría dominar artificialmente la formación de clusters.

Las pruebas de normalidad se utilizaron para determinar si era adecuado aplicar pruebas paramétricas o si era preferible usar métodos más robustos. Dado que varias variables no presentaron normalidad, se justificó el uso de correlación de *Spearman* en lugar de *Pearson* para ciertos análisis.

La correlación de *Spearman* se utilizó porque permite medir relaciones monotónicas entre variables sin exigir normalidad. Esto fue adecuado para variables como *MONTO APLICADO*, *PORCENTAJE DESCUENTO*, *EDAD*, *RECENCIA* y *MONTO_BRUTO*.

La prueba Chi-cuadrado se utilizó para evaluar asociación entre variables categóricas, como SEGMENTO_MONTO y GENERO. Esta técnica permite determinar si la distribución entre categorías es independiente o si existe una relación estadísticamente significativa.

El coeficiente *Cramér's V* se utilizó como complemento de la prueba Chi-cuadrado, ya que permite medir la intensidad de la asociación. Esto es importante porque una relación puede ser estadísticamente significativa, pero débil en términos prácticos.

El ANOVA se aplicó para comparar montos de venta entre grupos, como locales o canales. Esta técnica permite identificar si existen diferencias significativas entre categorías. En este caso, fue útil para detectar diferencias en MONTO APLICADO según LOCAL.

La prueba de *Tukey* se utilizó como complemento del ANOVA, ya que permite identificar entre qué grupos específicos existen diferencias. Esto mejora la interpretación de los resultados cuando el ANOVA indica que hay diferencias significativas generales.

Finalmente, se incorporó *K-Means* como modelo descriptivo porque permite segmentar clientes según similitud de comportamiento. Esta técnica es adecuada para el trabajo porque no requiere una variable objetivo, sino que agrupa observaciones a partir de características como frecuencia de compra, monto promedio, monto total, descuento promedio, edad y recencia. Además, se utilizó el método del codo para evaluar distintos valores de *k* y el *silhouette_score* para medir la calidad de separación de los grupos.

DIFICULTADES ENCONTRADAS Y CÓMO SE RESOLVIERON

Una de las principales dificultades fue el tamaño del archivo CSV, ya que contiene más de tres millones de registros. Una carga tradicional con *Pandas* podía generar un consumo excesivo de memoria. Para resolverlo, se utilizó *Dask*, que permite procesar el archivo en particiones y trabajar de manera más eficiente.

Otra dificultad fue la presencia de valores fuera de dominio y *outliers*. Se detectaron valores problemáticos en variables como PORCENTAJE DESCUENTO, MONTO APLICADO, BOLETA y LOCAL. Para resolver esto, se aplicaron reglas de validación y detección de *outliers* mediante *IQR*, transformando los valores inconsistentes en nulos para tratarlos posteriormente.

También fue necesario definir una estrategia adecuada para los valores faltantes. En vez de aplicar una única regla para todas las variables, se implementó una limpieza estratificada. Esto permitió eliminar registros cuando el porcentaje de nulos era bajo, imputar con mediana cuando era moderado y descartar variables cuando el nivel de ausencia era demasiado alto.

Otra dificultad fue que varias variables no seguían una distribución normal. Esto podía afectar la elección de pruebas estadísticas. Para resolverlo, se incorporaron pruebas de normalidad y se utilizaron técnicas más adecuadas cuando correspondía, como *Spearman* para correlaciones.

También se presentó un desbalance en algunas variables categóricas, especialmente en CANAL. Esto dificultó ciertas comparaciones estadísticas, ya que algunas categorías tenían muy pocos registros. Por esta razón, los resultados asociados a esas variables fueron interpretados con cautela.

Una dificultad adicional fue el control de memoria durante el análisis exploratorio y el modelado. Algunas pruebas estadísticas y gráficos requieren trabajar con datos en memoria, por lo que se implementó el uso de muestras acotadas. En el caso del *clustering*, aunque existían 1.177.083 clientes, se utilizó una muestra de 30.000 clientes, permitiendo aplicar *K-Means* sin comprometer la estabilidad del programa.

ANÁLISIS DE TIEMPOS DE EJECUCIÓN DEL PIPELINE

Si bien el análisis detallado de los tiempos de ejecución no fue solicitado explícitamente como parte de los entregables del trabajo, como grupo se consideró relevante incorporarlo dentro del desarrollo del informe. Esto se debe a que el proyecto no solo busca obtener resultados estadísticos a partir de los datos de ventas, sino también evaluar la eficiencia del procesamiento aplicado sobre un archivo de gran tamaño. Por esta razón, revisar la duración de cada etapa permite comprender mejor el comportamiento real del *pipeline* y detectar en qué momentos se concentran los mayores costos computacionales.

Bajo esta lógica, inicialmente podía suponerse que la carga del archivo CSV era el proceso más costoso, debido a que el dataset contiene más de tres millones de registros. Sin embargo, al revisar los tiempos registrados por el programa, se observa que la carga inicial no fue la etapa más lenta. La etapa 1, correspondiente a la carga del archivo con *Dask*, registró 3.242.878 registros, 15 columnas y 10 particiones, con un tiempo aproximado de 11,97 segundos. Esto muestra que la lectura particionada permitió manejar el archivo de forma eficiente en términos de carga inicial.

El proceso que presentó mayor tiempo de ejecución fue la Etapa 9, correspondiente al análisis exploratorio estadístico, con un tiempo total aproximado de 1.887,08 segundos. Esta etapa fue la más costosa porque incluye múltiples operaciones estadísticas y gráficas, tales como histogramas, análisis de variables básicas y deducidas, pruebas de normalidad, correlaciones, pruebas de asociación, ANOVA, *Tukey* y generación de gráficos. Aunque varias de estas tareas se ejecutan sobre muestras o mediante procesamiento paralelo en tareas independientes, siguen siendo operaciones pesadas, especialmente porque requieren calcular estadísticas, generar visualizaciones y guardar archivos de salida.

La segunda etapa con mayor demora fue la etapa 4, correspondiente al preprocesamiento de variables básicas, con un tiempo aproximado de 1.025,83 segundos. Esta demora se explica porque en dicha etapa se realiza el análisis de valores faltantes, la detección de outliers mediante *IQR*, el análisis del mecanismo de ausencia y la aplicación de la estrategia de limpieza estratificada. Varias de estas operaciones obligan a recorrer columnas completas del dataset o ejecutar cálculos sobre una gran cantidad de registros, por lo que su costo computacional es considerable.

En comparación, otras etapas tuvieron tiempos menores: la validación inicial demoró cerca de 34,16 segundos, el diagnóstico inicial 37,32 segundos, la creación de variables deducidas 22,92 segundos, el tratamiento de variables deducidas 71,67 segundos, la normalización 102,93 segundos y el modelado descriptivo con *clustering* 48,76 segundos. Esto permite concluir que el mayor problema de tiempo no estuvo en la carga del archivo ni en el modelo *K-Means*, sino principalmente en el análisis exploratorio estadístico y en el preprocesamiento de variables básicas.

Para abordar esta dificultad, se utilizaron *Dask*, particiones, muestreo y ejecución paralela de algunas pruebas independientes. Estas decisiones permitieron que el procesamiento fuera

viable y evitaron una sobrecarga de memoria. Sin embargo, no fue posible reducir completamente el tiempo total de ejecución, ya que varias operaciones requieren calcular resultados reales sobre el dataset o sobre muestras representativas, además de generar y guardar múltiples gráficos. Por lo tanto, la mejora principal no fue eliminar la demora, sino controlar el uso de memoria, organizar el procesamiento por etapas y dejar evidencia del tiempo real de ejecución para identificar los cuellos de botella del *pipeline*.

CONCLUSIÓN

El desarrollo de este trabajo permitió implementar una solución computacional orientada al procesamiento, análisis estadístico y modelado descriptivo de un archivo de ventas de gran tamaño correspondiente al caso de estudio de Cruz Morada. A través del *pipeline* desarrollado, fue posible abordar distintas etapas del análisis de datos, comenzando por la carga eficiente del archivo CSV, la validación de tipos y reglas de dominio, el diagnóstico inicial, el tratamiento de valores faltantes, la detección de valores atípicos, la creación de variables deducidas, el análisis exploratorio estadístico y, finalmente, la segmentación de clientes mediante un modelo descriptivo de clustering *K-Means*.

Uno de los aspectos más relevantes de la solución fue el uso de *Dask* para la carga y procesamiento inicial del *dataset*. Esta herramienta permitió trabajar con más de tres millones de registros mediante particiones, evitando cargar todo el archivo directamente en memoria. De esta manera, el programa logró responder al requerimiento de procesar archivos grandes de forma eficiente, manteniendo un uso más controlado de los recursos computacionales. Además, la estructura modular del código facilitó la organización del proceso en etapas claras, reproducibles y trazables.

Desde el punto de vista estadístico, el trabajo permitió caracterizar el comportamiento general de las ventas mediante estadísticas descriptivas, pruebas de normalidad, correlaciones, pruebas de asociación, ANOVA y visualizaciones. Los resultados mostraron que varias variables no seguían una distribución normal, lo que justificó el uso de métodos más robustos, como la correlación de *Spearman*. También se identificaron relaciones relevantes entre variables, diferencias significativas en los montos de venta según local y asociaciones débiles entre algunas variables categóricas. Esto permitió transformar los datos transaccionales en información útil para interpretar patrones de comportamiento comercial.

La incorporación del modelo descriptivo mediante *clustering K-Means* permitió complementar el análisis estadístico con una segmentación de clientes. A partir de variables como frecuencia de compra, monto promedio, monto total, descuento promedio, edad promedio y recencia, se identificaron tres perfiles generales de clientes: clientes frecuentes y de mayor valor, clientes de compra menos frecuente pero con montos relativamente altos, y clientes menos activos con compras de menor monto. Si bien el *silhouette_score* obtenido indica una separación moderada-baja entre los grupos, el modelo cumple una función descriptiva útil, ya que permite observar tendencias generales y apoyar posibles estrategias comerciales diferenciadas.

Respecto al paralelismo, es importante señalar que el código sí incorpora mecanismos de procesamiento paralelo, pero no todo el pipeline se ejecuta de forma paralela. El flujo general del programa mantiene una estructura secuencial por etapas, ya que cada fase depende del resultado de la anterior. Por ejemplo, primero se debe cargar el archivo, luego validarlo, después limpiarlo, generar variables, realizar análisis exploratorio y finalmente aplicar el modelo de *clustering*. Sin embargo, dentro de estas etapas sí se aplican técnicas paralelas, principalmente mediante *Dask*, que procesa el archivo CSV en particiones, y mediante

ThreadPoolExecutor, que permite ejecutar pruebas estadísticas independientes en paralelo durante el análisis exploratorio.

Por lo tanto, la solución no corresponde a un sistema completamente paralelo o distribuido en todos sus componentes, como podría ocurrir con una arquitectura basada en múltiples nodos. Más bien, implementa paralelismo de manera focalizada en las partes donde entrega mayor beneficio: la carga y procesamiento de grandes volúmenes de datos, y la ejecución de tareas estadísticas independientes. Esta decisión resulta adecuada para el alcance del trabajo, ya que permite mejorar el rendimiento sin aumentar excesivamente la complejidad del código.

En síntesis, el trabajo desarrollado cumple con los objetivos principales propuestos, ya que permite procesar un archivo grande, aplicar limpieza y transformación de datos, realizar análisis estadístico, generar evidencia visual y construir un modelo descriptivo de segmentación. Además, la solución mantiene reproducibilidad mediante el uso de una semilla configurable, organiza sus resultados en archivos de salida y utiliza paralelismo de manera práctica y controlada. Como mejora futura, se podría profundizar en un paralelismo más avanzado o distribuido, ampliar la validación del modelo de clustering con nuevas variables o comparar *K-Means* con otros métodos de segmentación. Aun así, la versión actual representa una solución sólida, coherente con los requerimientos del trabajo y útil para extraer conocimiento de valor a partir de los datos de ventas.

ANEXOS

(1) Link del trabajo subido a Github

https://github.com/JoMi-MorV/Problema_2_Computacion_Paralela.git